ENN, HW1 Сухова Софья

Архитектура

3 канала

Conv 7×7, s=2, 3→32 (1)
MaxPool 3×3, s=2, p=1 (2)
Conv 5×5, s=1, 32→64 (3)
Conv 3×3, s=2, 64→128 (4)
Conv 1×1, s=1, 128→256 (5)
Conv 3×3, s=2, 256→~~256~~ (6)
Conv 1×1, s=1, 256→512 (7)
GAP → Linear 512→256 (8)
ReLU → Linear 256→100 (9)

у Conv $p = \lfloor K/2 \rfloor$

Для свертки и пулинга: $H_{out} = \left\lfloor \frac{H_{in} + 2p - K}{s} \right\rfloor + 1$

(1): $H_1 = \left\lfloor \frac{S + 6 - 7}{2} \right\rfloor + 1 = \frac{S}{2}$ (S - чётное)

(2): $H_2 = \left\lfloor \frac{S/2 + 2 - 3}{2} \right\rfloor + 1 = \frac{S}{4}$

(3): $H_3 = \left\lfloor \frac{S/4 + 4 - 5}{1} \right\rfloor + 1 = \frac{S}{4}$

при s=1 размер сохраняется, при s=2 уменьшается вдвое.

(4): $\frac{S}{8}$ (5): $\frac{S}{8}$ (6): $\frac{S}{16}$ (7): $\frac{S}{16}$

C_{in} - вход. кан. k - ядро
C_{out} - выход. кан. H_{out}, W_{out} - выс. × шир.
B - batch

$$FLOPs(S,B) = F_{conv} + F_{maxpool} + F_{ReLU} + F_{GAP} + F_{Linear}$$

1) F_{conv}

1 фильтр: $C_{in}K^2$ => { MAC = 2FLOP } => $2C_{in}K^2$

выходных чисел: $B H_{out} W_{out} C_{out}$

=> $F_{conv} = 2B H_{out} W_{out} C_{out} C_{in} K^2$

$F_1 = 2 \cdot B \cdot \frac{S}{2} \cdot \frac{S}{2} \cdot 32 \cdot 3 \cdot 49 = 2352 BS^2$

$F_3 = 2 \cdot B \cdot (\frac{S}{4})^2 \cdot 64 \cdot 32 \cdot 25 = 6400 BS^2$

$F_4 = 2 \cdot B \cdot (\frac{S}{8})^2 \cdot 128 \cdot 64 \cdot 3^2 = 2304 BS^2$

$F_5 = 2B \cdot (\frac{S}{8})^2 \cdot 256 \cdot 128 = 1024 BS^2$

$F_6 = 2B \cdot (\frac{S}{16})^2 \cdot 256 \cdot 256 \cdot 9 = 4608 BS^2$

$F_7 = 2B \cdot (\frac{S}{16})^2 \cdot 512 \cdot 256 = 1024 BS^2$

$F_{conv} = \sum_{k} F_k = (\dots) BS^2 = \underline{17712 BS^2}$

2) MaxPool

3×3 → max из 9 чисел => 8 сравнений

кол-во вых. чисел: $B \times 32 \times (\frac{S}{4})^2 = 2BS^2$

$F_{pool} = \underline{16 BS^2}$

3) ReLU

1 сравнение с нулем. => число эл-в после каждой свёртки ReLU =>

$F_{ReLU,conv} (8+4+2+4+1+2) BS^2 = \underline{21 BS^2}$

последнее ReLU пока не учитывается

4) GAP

Sie kaskado: $y = \underbrace{\frac{x_1 + \dots x_n}{n}}$, wo $n = \left(\frac{S}{16}\right)^2$

n-1 sloth. => n operacij
1 del.

$$F_{GAP} = B \cdot 512 \cdot \left(\frac{S}{16}\right)^2 = \underline{\underline{2BS^2}}$$

5) Linear

$512 \rightarrow 256 \rightarrow 100$
(1) (2)

(1): Dve 120 512 MAC + Bias + ReLU
$\Rightarrow 512 \cdot 256$ MAC $\Rightarrow 2 \cdot 512 \cdot 256 \cdot B$ FLOPs

$\Rightarrow 2 \cdot 512 \cdot 256 \cdot b + \underset{\text{Bias}}{256 \cdot B} + \underset{\text{ReLU}}{256 B}$

(2): $2B \cdot 256 \cdot 100 + \underset{\text{Bias}}{100 B}$

$F_{Linear} = 2 \cdot 512 \cdot 256 B + 512 B + 2B \cdot 256 \cdot 100 + 100 B$
$= \underline{\underline{313956 B}}$

$\boxed{FLOPs} = \sum FLOPs_i = 313956 B + 2BS^2 + 21BS^2 + 16BS^2 + 17712 BS^2 = \underline{\underline{(177512S^2 + 313956) B}}$

$\underline{\text{Memory}(S,B)} = \underset{\uparrow \text{FP32}}{4} (N_{par} + N_{peak})$

Веса в свертках и линейных.

Conv

1 фильтр $\Rightarrow N_{conv} = C_{in} K^2$

Сколько фильтров $\Rightarrow N_{conv} = C_{out} C_{in} K^2$

$N_1 = 4704$ $N_3 = 51200$ $N_4 = 73728$

$N_5 = 32768$ $N_6 = 589824$ $N_7 = 131072$

Linear

$512 \to 256$ $256 \to 100$

Каждый выходной нейрон связан со всеми входными знач-ми.

$N_{Linear} = N_{in} N_{out} + \underbrace{N_{out}}_{bias}$

$N_{11} = 512 \cdot 256 + 256 = 131328$

$N_{22} = 256 \cdot 100 + 100 = 25700$

$N_{par} = N_{conv} + N_{Linear} = 1040324$

Активации.

исходный тензор X сохраняется на протяжении всего форварда. На каждом этапе учитываем вход + выход + X.

$N_{act} = N_x + N_{in} + N_{out}$

$N_1 = 3BS^2 + 8BS^2 = 11BS^2$ conv1

$N_2 = 3BS^2 + 8BS^2 + 2BS^2 = 13BS^2$ maxPool

Max (2+4, 4+2, 2+4, 4+1, 1+2) $BS^2 = 6BS^2 \leq \underbrace{3BS^2}_{X} + 6BS^2 = 9BS^2$

$\Rightarrow$ MaxPool максимален

$\rightarrow$ **Memory (S, B)** $= 4(1040324 + 13BS^2)$

BytesMoved (S, B) $= 4(N_{in} + N_{weights} + N_{out})$

Операция	N_{in} Вход	N_{out} Выход	$N_{weights}$ Веса
$Conv_1$	$3BS^2$	$8BS^2$	4704
$ReLU_1$	$8BS^2$	$8BS^2$	0
MaxPool	$8BS^2$	$2BS^2$	0
$Conv_2$	$2BS^2$	$4BS^2$	51200
$ReLU_2$	$4BS^2$	$4BS^2$	0
$Conv_3$	$4BS^2$	$2BS^2$	73728
$ReLU_3$	$2BS^2$	$2BS^2$	0
$Conv_4$	$2BS^2$	$4BS^2$	32768
$ReLU_4$	$4BS^2$	$4BS^2$	0
$Conv_5$	$4BS^2$	BS^2	589824
$ReLU_5$	BS^2	BS^2	0
$Conv_6$	BS^2	$2BS^2$	131072
$ReLU_6$	$2BS^2$	$2BS^2$	0
GAP	$2BS^2$	512B	0
Linear1	512B	256B	131328
ReLU	256B	256B	0
$Linear_2$	256B	100B	25700

$\Sigma = 91BS^2 + 2148B + 1040324$

BytesMoved (S, B) $= 4(91BS^2 + 2148B + 1040324)$

Latency (S, B)

Введем пар-ры GPU

t_{launch} — время запуска одного оператора (с)

P_e — эфф. выч. проуз-ть GPU (FLOP/c)

BW_e - пропуск. сп-ть памяти (байт/с)

$\theta_{\xi} = (t_{launch}, P_e, BW_e)$

1) Время вычислений: кол-во оп / скорость выпол-я оне проуб. слоя i:

$$t_{1,i} = \frac{F_i}{P_e} \leftarrow \text{FLOPs слоя i}$$

2) Время перемещения данных:

$$t_{2,i} = \frac{Q_i}{BW_e} \leftarrow \text{Bytes Moved слоя i}$$

3) Вычисление и передача могут накладываться

$$\Rightarrow t_i = \underbrace{\max\left(\frac{F_i}{P_e}; \frac{Q_i}{BW_e}\right)}_{\text{время работы}} + \underbrace{t_{launch}}_{\text{время запуска}}$$

сеть последовательная:

Conv	6 шт	GAP	1 шт
RELU	7 шт	Linear	2 шт
MaxPool	1 шт		

} 17 оп.

$$\Rightarrow \boxed{Latency(S, B; \theta)} = \sum_{1}^{17} \left(\max\left(\frac{F_i(S,B)}{P_e}, \frac{Q_i(S,B)}{BW_e}\right) + t_{launch}\right)$$

Режимы работы

1. Launch - bound

$$t_{launch} >> \max\left(\frac{F_i}{P_e}, \frac{Q_i}{BW_e}\right) \text{ и } t_i \approx t_{launch}$$

2. Memory - bound

$$\frac{Q_i}{BW_e} >> \max\left(\frac{F_i}{P_e}, t_{launch}\right) \text{ и } t_i \approx \frac{Q_i}{BW_e}$$

3. Compute - bound

$$\frac{F_i}{P_e} >> \max\left(\frac{Q_i}{BW_e}, t_{launch}\right) \text{ и } t_i \approx \frac{F_i}{P_e}$$

$Energy(S,B) = E_{launch} + E_{compute} + E_{mem}$

1) Энергия запуска яд. ~~e launch~~

e_{launch} – эн. одного запуска (Дж)

$E_{launch} = 17 e_{launch}$ (17 операторов)

2) Энергия вычислений:

Эн. на 1 FLOP расх-ся e_{FLOP} Дж.

$\Rightarrow E_{compute} = e_{FLOP} \cdot FLOPs(S,B) =$

$= e_{FLOPs} \cdot B(177515S^2 + 313956)$

3) Энергия перемещения:

e_{byte} – эн. перем. 1 байта

$\Rightarrow E_{mem} = e_{byte} \cdot BytesMoved(S,B) =$

$= 4 e_{byte} \cdot (91BS^2 + 2148B + 1040324)$

$\Rightarrow$ **$Energy(S,B) = 17 e_{launch} +$**

$+ e_{FLOP} \cdot B(177515S^2 + 313956) +$

$+ 4 e_{byte} \cdot (91BS^2 + 2148B + 1040324)$

Допущения!

FP32; model.eval(); torch.inference_mode();

Latency – медиана времени одного forward

Memory – peak torch.cuda.max_memory_allocated() на forward

Для BytesMoved вход и веса читаются 1 раз, выход пишется 1 раз

Energy – энергия всей GPU на 1 forward, Дж.